

Logbuch — KI1-Projekt 308

Name: Björn Philipp Becker

Gruppe: 308

Zeitraum: 20.02.2026 – 15.04.2026

Matrikelnummer 8206290

Eintrag 1

Datum: 19.02.2026 & 20.02.2026

Titel: Projektstart — Aufgabe lesen, Repository einrichten

Aus Gruppentreffen: Eigenständig und Gruppentreffen 1 (20.02.2026)

Arbeitsschritte:

- Aufgabenstellung gelesen und verstanden
- Recherche, wie man an den Datensatz kommt (Am Ende aus Übung)
- Über GitLab informiert (im Gruppentreffen dann aber anders entschieden, da keiner sich wirklich damit auskennt, aber Florian ordentlich mit GitHub)
- Wiederholung der Vorlesungsfolien
- Repository geklont
- `nbstripout --install` eingerichtet
- Erste Übersicht über den California Housing Datensatz verschafft

Schwierigkeiten / offene Fragen:

- Wie kann das Projekt funktionieren, wenn wir so verschiedene Zeitfenster haben

Eintrag 2

Datum: 17.03.2026

Titel: Wiederholung der Vorlesung und Einlesen in Ergebnisse der Gruppenmitglieder

Aus Gruppentreffen: Eigenständig

Arbeitsschritte:

- Aufgrund von Tensorflow musste die Python Version von 3.14 auf 3.12 heruntergestuft werden.
- Nachvollziehen des Aufbaus des Git-Workspace. Requirements installiert.
- Lesen und Verstehen der Notebooks vor den Neuronalen Netzwerken, die später zum Ensemble-learning beitragen könnten.
- Nochmals Vorlesung wiederholen und dabei vorläufig Ideen entwickeln, an welche Aufgaben ich mich setzen möchte. (Pooling der geographischen Lage, Transformation der Daten(Feature Engineering), Learning-Rate-Scheduler. Ich weiß aus vorherigen Gruppentreffen, dass Hyperparameter wie Form, Lernrate oder Aktivierungsfunktionen schon ausführlich

behandelt wurden).

zusätzliche Recherche mit Google

- Einlesen in Fortschritt der Gruppenmitglieder (NN-Notebooks)
 - dabei wird klar, dass einige Ideen schon umgesetzt wurden
- Überfliegen von Felix H. Logbuch

Entscheidungen:

- ich möchte mich nicht so sehr mit der Form des NN auseinandersetzen, sondern an genannten Dingen arbeiten
 - Pooling (auch wenn Aussicht auf Erfolg nicht so groß ist)
- ich lege mir eine kleine Analoge Formelsammlung für das Projekt und die Umgebung an.

Schwierigkeiten / offene Fragen:

- Das Ausführen der Notebooks der anderen Gruppenmitglieder dauert sehr lange - sollte ich es im JupiterHub der Uni probieren, welchem ich mehr Rechenleistung adhästiere. (spätere Ergänzung: mir wurde in einem späteren Gruppentreffen verdeutlicht, dass ich mich wohl täuschte)

Eintrag 3

Datum: 18.03.2026

Titel: Anfänge und erste Erkenntnisse

Aus Gruppentreffen: Angelehnt an Gruppentreffen 5 am 17.03.

Arbeitsschritte:

- Aus den Ergebnissen von Kolja und Felix H. haben wir Schlüsse über die Größenordnung von Parametern gezogen. Außerdem war Ergebnis, dass die Aktivierungsfunktion kaum Einfluss auf die Ergebnisse hat, weswegen ich heute nur ReLu nutzte, da diese effizient ist (vgl. [StudySmarter](#) Zugriff: 18.03.).
- Ich wollte mich zuerst mit dem grundsätzlichen Coden eines einfachen Neuronalen Netzes auseinandersetzen. Dazu habe ich Modulimporte und Skalierung der bereinigten Daten aus den Gruppenergebnissen übernommen. Da Felix H. herausfand, dass nur ["MedInc", "AveOccup", "Latitude", "Longitude"] Informationsgewinn bieten und die anderen Daten eher zum Rauschen beitragen, entschied ich mich, nur diese 4 zu benutzen.
- Meine ersten beiden kleinen Netze, die ich mit einer L2 Regularisierung zur Vermeidung von Overfitting (Die Nützlichkeit hatte Kolja beim Gruppentreffen eingebracht), kleinem Dropout und mit EarlyStopping ausgestattet hatte, ergaben ordentliche Ergebnisse mit einem R2 von knapp über 0.7 und wenig Overfitting.
- Wie im Gruppentreffen besprochen, ist die erste Aufgabe, ein sehr gutes Netz aus den bisherigen Erkenntnissen zu bauen. Ich erwartete, da bisher die Hyperparameter eher einzeln getestet wurden, Probleme mit lokalen Minima zu bekommen. Deswegen nutze ich Random-Search. Hyperparametereingrenzung ergaben sich aus den Ergebnissen der Anderen mit Abgleich mit ChatGPT: Ergebnis:
 - Neuronen: 32, 64, 128
 - Layer: 2, 3
 - Learning Rate: $1e-4$ – $1e-2$ (log)
 - L2: $1e-5$ – $1e-3$
 - Dropout: 0.1 – 0.3
 - Batch Size: 16, 32, 64
 - Epochs: max 100 (EarlyStopping)
 - Aktivierung: ReLU

- Ich erwartete eine enorme Rechenzeit und deswegen informierte ich mich über Parallelisierung
- Ergebnis:

	run_id	R ² Val	R ² Test	units	depth	lr	l2	dropout	batch_size	epochs
27	27	0.757183	0.743349	128	2	0.000343	0.000052	0.156997	16	81
33	33	0.751369	0.736966	128	2	0.001588	0.000024	0.163947	16	66
29	29	0.750405	0.736433	128	2	0.000395	0.000017	0.256285	64	93
16	16	0.747135	0.733957	64	3	0.000941	0.000284	0.116963	16	77
13	13	0.746669	0.733977	128	3	0.001095	0.000016	0.195057	32	61

- Ich hoffte Zusammenhänge sehen zu können, aber das ist nicht der Fall. Deswegen werde ich den Code erneut Ausführen und die besten Ergebnisse sammeln. Ich erhoffe mir mit einer größeren Menge an Daten eine gescheite lineare Regression durchzuführen, um Zusammenhänge zu verstehen.
- Beim nochmaligen darüber Nachdenken bin ich nun nicht mehr so überzeugt, dass die lin. reg so viel bringt. Frage ChatGPT: Welche anderen Möglichkeiten gibt es, die Daten in eine verständliche Form zu bringen? - PDP (Partial Dependence Plots) mit RandomForestGenerator
 - die PDP grenzen die Hyperparameter weiter ein
 - so wie Florian die Feature Importance herausgefunden hat, kann man jetzt die Hyperparameter Importance aus dem Random Forest ausgeben lassen
 - dieses Metamodell zeigt den Zusammenhang zwischen den Hyperparametern und dem R² Score.
 - Jetzt kann man iterativ **Random**-/ oder Grid-Search machen und die Hyperparameter weiter eingrenzen

(siehe dazu in results: pdp.png und Hyperparameter_Importance.png)

Entscheidungen:

- Morgen mache ich das ganze nochmal mit einem größeren Datensatz
- Ich möchte schauen, wie gut die Netze werden, wenn man den Vorgang mehrfach Wiederholt

Schwierigkeiten / offene Fragen:

- Macht es Sinn, die Zeit aufzuwenden mehr Daten anzusammeln? Wie gut kann das werden? Laufe ich in eine Sackgasse?

Eintrag 4

Datum: 19.03.2026

Titel: erste Iterationen

Aus Gruppentreffen: 5 vom 17.03.

Arbeitsschritte:

- Ich erweitere meinen Datensatz, um bei den PDP und Hyperparameter-Importances klare Schlüsse ziehen zu können. Bisher besteht mein Datensatz nur aus den 30 besten Einträgen der vorherigen Runs.

- zu sehr werde ich es nicht erweitern, da ich das Gefühl bekomme, Tendenzen jetzt schon abschätzen zu können. Es braucht sehr viel Rechenzeit
 - Es hat sich gelohnt zu warten. Der neue Datensatz mit nun 50 Einträgen zeigt eine andere Tendenz für die Batchsize. (Vorher 32, jetzt 16). Die Tiefe scheint ziemlich egal zu sein. Bei der Hyperparameter-Importance gewinnt die Batchsize stark an Einfluss. Es lässt sich nur mit schwacher Sicherheit sagen, dass die Anzahl der Units pro Layer und die Tiefe eine vergleichbar kleine Rolle spielen. Dagegen sind wahrscheinlich "dropout", "Lernrate" und "L2-Regularisierungsfaktor" von großer Bedeutung.
 - ich finde es etwas Überraschend, dass hier "L2" wichtig ist
 - Das ganze Vorgehen entspricht nicht meiner Intuition. Ich bin mir unsicher, wie die Ergebnisse zu interpretieren sind
 - Ich werde nun trotzdem die Hyperparameter anhand der PDP eingrenzen.
 - Units: bleibt - aber Zufallsverteilung eher Richtung 128
 - depth: das Ergebnis ist ziemlich waagerecht. Ich nehme mal noch die 4 hinzu und schaue was passiert
 - batch size nur noch 16 und 32
 - dropout: Nur noch 0.1 - 0.16
 - lr: bleibt
 - l2: bleibt
 - ich hatte vorher noch die Möglichkeit, dass auch Netze über 50 Epochen gerechnet werden konnten. In den Ergebnissen ist kein Abbruch vor 50 Epochen zu sehen, daher wird es entfernt und auf 100 festgelegt (mit Earlystop).
 - mit den Ergebnissen der anderen Gruppenmitgliedern im Kopf, sind mehr Epochen sehr wahrscheinlich besser, aber die Rechenzeit ist einfach zu enorm, als das ich es ausprobieren könnte. Vielleicht mal über Nacht.
 - Nun habe ich die Ergebnisse:
 - Die neuen Netze neigen maginal weniger zum Overfitting, was auch vorher kein großes problem war. In der Spitze sind die neuen Netze laut dem R2 Wert tatsächlich nicht besser. Der Vergleich ist aber unfair, da jetzt ca. 400 Netze mit 200 Netzen verglichen werden
 - auf Platz 20 für den besten Testscore ist aber eine leichte Verbesserung zu sehen, trotz ungerechtem Vergleich.
 - In der Breite ist es nun besser geworden
 - Aus PDP und Hyperparameter-Importance kann man nun sehen, dass 4 Layer nicht gut sind und eine Einschränkung des Dropouts auf 0.115 - 0.15 Sinn machen könnte. Ich werde nun die Parameter nochmal verändern und das Ergebnis dann zu meinem neuen Datensatz hinzufügen. Außerdem werde ich mal 200 Epochen als Maximalwert ausprobieren
 - 200 Epochen zu nutzen war sehr gut. Die Hyperparameter-Importance zeigt nun, dass der wichtigste Parameter nun die Lernrate ist.
 -  Hyperparameter-Importance
 -  PDP Nr.3
- Mit Blick auf die Lernrate stellt sich die Frage, ob das erlaubte Intervall optimal angesetzt ist. Speziell werde ich mir kleinere Lernraten ansehen ab 10^{-6} .
- Die Ergebnisse werden nicht besser

Entscheidungen:

- Ensemble aus Netzen mit den gesamten California Housing testen. Ich habe noch Baysche Netze im Kopf(ohne genau zu wissen was das ist, aber das passt glaube ich zu dem Thema.
Das ist eher eine Rechercheaufgabe)

Schwierigkeiten / offene Fragen:

- Der heutige Tag war vor allem von warten geprägt. Die Ausführung des Codes dauert jeweils mehr als eine Stunde.

Eintrag 5

Datum: 20.03.

Titel: erstes Ensemble

Aus Gruppentreffen: 5 vom 17.03.

Arbeitsschritte:

- Jetzt ein letztes mal Parameteranpassung. Lernrate (logarithmisch) wird auf Intervall $[-3.3; -2]$ begrenzt.
- Über Nacht habe ich darüber nachgedacht, ob es eine gute Entscheidung war, immer wieder die schlechten Netze zu löschen. Vielleicht könnten diese Ergebnisse das Gesamtergebnis verbessern.
- Die Verbesserung hat gute Ergebnisse erzieht. Ich werde die Epochen auf 500 hochschrauben, da viele Netze die 200 max Epochen zum lernen nutzen. Diese Netze sind wirklich gut, aber kaum entschieden besser als vorher.
- Ich hatte vorher schon die Units gewichtet. Vorher war es stark favorisiert in Richtung 128, jetzt immer noch, aber weniger stark. Ich möchte mehr diversifizieren, da ich nur NN für die späteren Ensembles benutze, was sehr wichtig ist (vgl. Vorlesung 7, S.11). Ich nehme eine Hand voll der Netze und benötige noch ein paar schwächere mit stark anderen Hyperparametern
- ich dachte eigentlich, dass wir einen gemeinsamen Speicher von unseren besten Netzen haben, aber das einzige, dass ich fand, war eine leere Liste, die nur Einträge im Arbeitsspeicher vermerkt.
- Ich habe jetzt ein Ensemble gebaut. Leider ist das Ergebnis mit $R^2 = 0.7499$ nur wenig besser als der Durchschnitt der einzelnen Netze.
-

Entscheidungen:

- Aufgrund der nicht so bereichernden Ergebnisse heute, möchte ich morgen das gleiche mit allen Features machen.
 - entweder der Score wird besser, oder der Score wird schlechter. Im zweiten Fall müsste ich dann die Hyperparameter nochmal neu anpassen. - Also wieder Random-Search
- Außerdem finde ich spannend die Features zu verknüpfen

Schwierigkeiten / offene Fragen:

- Es ist schwer die Ergebnisse einzuordnen, da nicht hinreichend unterschieden werden kann zwischen statistischen Schwankungen und Wahrheit.

Eintrag 6

Datum: 21.03.

Titel: Feature Anpassung

Aus Gruppentreffen: Eigenständig, aber aufbauend auf Gruppentreffen 5

Arbeitsschritte:

- Ich trainiere das Ensemble nun auf den gesamten California Housing Datensatz. Der Score ist 0.78 und damit deutlich besser als zuvor. Ich werde das Ensemble noch ein paar mal ausführen, um abzuschätzen, wie groß das Rauschen ist. (Ergebnisse: 0.778, 0.7795, 0.788, 0.7807, 0.7809)
- Fragte ChatGPT: welche Features des California Housing Datensatz kann man verbinden, sodass ein besseres NN entsteht?
 - ... Diese sind besonders effektiv: AveRooms / AveOccup, AveBedrms / AveRooms, Population / AveOccup, MedInc /

AveOccup ... Es sollten die normierten Daten verwendet werden.

- Ich habe heute keine Lust mehr mich mit Python Fehlern auseinander zu setzen

Eintrag 7

Datum: 23.03.

Titel: Anfang Dokumentation

Aus Gruppentreffen: Eigenständig

Arbeitsschritte:

- Habe einen schwer zu identifizierenden Fehler. Der Score des aktuellen Ensembles ist ?negativ?.
 - in meinen Daten ist ein einziger Wert nicht Non-Null. Grund könnte ein geteilt durch 0 Problem beim Feature Engineering sein, dass ich durch das Hinzufügen eines kleinen Wertes in den Nenner zu beheben versuche.
 - Der score ist nun 0.65
 - Außerdem ist die Skalierung im Eimer. Wahrscheinlich macht es Sinn, erst Feature Engineering mit den Ursprungsdaten zu machen und dann alle gemeinsam zu skalieren.
 - Der Score von nun 0.765 ist etwas enttäuschend
- Nach einer längeren Lagebesprechung mit Felix N. haben wir uns für heute dazu entschieden, wie auch im Gruppentreffen 5 vereinbart, schonmal die Ergebnisse des Projektes zusammen zu fassen. Gesprächsthemen waren außerdem der aktuelle Stand und formale Themen. Außerdem werde ich mich im Verlauf des heutigen Tages mit meinem Notebook beschäftigen in Sachen Lesbarkeit und Dokumentation.

Eintrag 8

Datum: 24.03

Titel: Enttäuschende Ergebnisse

Aus Gruppentreffen: 5

Arbeitsschritte:

- Ich habe nun endlich den Fehler in meinem Code gefunden und noch einen weiteren aufgedeckt. Er betrifft das gestrige Ensemble(vor feature Engineering). Ich hoffe nun bessere Ergebnisse zu bekommen. - 0.768
- Ich habe nun also noch einmal Random-serach verwendet, um für den erweiterten Datensatz gute netze zu finden. Allerdings ist das Ergebnis mit 0.67 wirklich schwach. ich muss wahrscheinlich nochmal die Parameterspannen erweitern.
 - möglich wäre auch dass die maximale Anzahl von 200 Epochen zu wenig ist, um die Netze hinreichend zu trainieren. Deswegen nun in allen Hyperparametern größere Spannen und mehr Epochen. - Das hat wieder gar nichts gebracht.
- Die nächste Idee war, die Architektur ein bisschen zu diversifizieren. Das bringt ein bisschen Verbesserung, aber nicht relevant.
- Ich speichere das trotzdem mal ab. Ganz zum Schluss möchte ich ein weighted Ensemble bauen. Dafür brauche ich die Bestandteile so verschieden wie möglich.
 - ich muss dann noch den Shirnk-Faktor zwei bei den anderen gespeicherten Netzen hinzufügen.
- was ich beim feature-Engineering noch ausgelassen habe, ist y zu verändern. Ich erhoffe mir wenig davon, aber ein Versuch ist es Wert. Man könnte sich da viel überlegen, aber ich nehme der Einfachheit halber die Ursprungsdaten, also

nicht wie sonst die Normalisierten. Das spuckt Fehler aus, die ich nicht identifizieren kann. Ich werde mich bis ich wieder motivation zur Fehlersuche gesammelt habe etwas anderes.

- Ich bin mittlerweile zu dem Schluss gekommen, dass die neu gewählten Features einfach schlecht waren.
 - Ich habe dazu ChatGPT gefragt, was bessere Features sind: "kannst du mir bessere features zum engineeren vorschlagen"
 - "MedInc" * "AveRooms"
 - "MedInc" * "Population"
 - Distanz zum Zentrum: $((\text{"Latitude"} - 36)^2 + (\text{"Longitude"} + 119)^2)^{-1/2}$
 - "AveOcc"²
 - $\log(\text{"Population"})$
 - ich ersetze also...
- nach 4 Stunden Ladezeit ist auch hier der score unter 0.7, was wieder nicht so optimal ist.

Eintrag 9

Datum: 25.03.

Titel: Letzes Ensemble

Aus Gruppentreffen: Eigenständig

Arbeitsschritte:

- Ich nutze nochmal Random-Search und füge einen neuen Hyperparameter hinzu. Ich möchte, dass die Architektur nicht jedes mal so aussieht, dass die Layer sich in der Größe halbieren.
- Habe ein neues Ensemble gebaut mit dieser Erweiterung und mit den drei verschiedenen Datensätzen getestet
- Beginne mit dem Schreiben meiner Logbuchzusammenfassung

Eintrag 10

Datum: 26.03.

Titel: Dokumentation

Arbeitsschritte:

- Aufgrund von Problemen mit Git sind meine Zellenoutputs nicht mehr einsehbar.
 - Leider habe ich die Ergebnisse von den Ensembles nicht dokumentiert.
- Schreibe heute an meiner Zusammenfassung weiter
- Heute Abend ist unser letztes Gruppentreffen

Eintrag 11

Datum: 26.03.

Titel: Dokumentation

Arbeitsschritte:

- Ich finde leider nicht mal mehr den Code (siehe Eintrag 9 und 10) in unserem Git und auch nicht im Git-Verlauf. Ich bin mir sicher, gespeichert zu haben...
 - da ich eigentlich schon über den 75 Stunden bin und noch Dokumentation und Bewertung der Gruppenmitglieder schreiben muss, werde ich das jetzt auf sich beruhen lassen. Ich weiß noch, dass der Score mein bestes bisheriges Ensemble nicht übertraf, was mich zumindest etwas beruhigt. Das Ensemble ist auch nicht mehr zu finden.
- Ich schreibe an meiner Dokumentation und überarbeite mein Notebook ein kleines bisschen.
- Ich schreibe die Bewertung der Gruppenmitglieder.