

Name: Felix Neumann **Gruppe:** 308

Zeitraum: 20.02.2026 – 15.04.2026

Eintrag 1

Datum: 20.02.2026 **Titel:** Projektstart — Aufgabe lesen, Repository einrichten

Aus Gruppentreffen: [1] (20.02.2026) (ca. 2 h)

Arbeitsschritte:

- Aufgabenstellung gelesen und verstanden
 - Repository geklont, Packages installiert (`pip install -r requirements.txt`)
 - `nbstripout --install` eingerichtet
 - Erste Übersicht über den California Housing Datensatz verschafft (`fetch_california_housing()`, 8 Features, Zielvariable: `MedHouseVal`)
 - Besprechung allgemeines Vorgehen
 - Einlesen in verschiedene Formen des NN
 - verknüpfen Vorlesungsinhalte mit Implimentationen im Notebook
 - einrichten Github zum Austausch der Inhalte
-

Eintrag 2 (ca. 6 h)

Datum: 17.03.2026 **Titel:** [Allgemeine Einarbeitung]

Aus Gruppentreffen: [4, 5]

Arbeitsschritte:

- Vorbereitung VS-Code
- Versuch Codeausführung mit bereits eingerichtetem KI1-Environment
- Neuinitialisierung Python environment
 - Pakete installiert
 - Problemlösen Tensorflow
- Einlesen in neuste Änderungen der Gruppenmitglieder
- Aufarbeitung Vorlesungsinhalte
- einarbeitung in Git
- Gruppentreffen 5 (siehe Gruppentreffen)
 - Absprache zur Zeitaufteilung und Bearbeitung der NN
- logbuch angelegt
- Recherche allgemein zu vorgehen beim Aufbau neuronaler Netze

- Ausarbeitung zu Ideen zu:
 - random search, grid search, Datentransformation, drop out und weigth decay
- Einlesen in Fachliteratur, insbesondere: [Stuart J. Russell, Peter Norvig (2020-4th Ed.): Artificial Intelligence: A Modern Approach, Prentice Hall] **Entscheidungen:**
- Python 3.11.15 verwenden
- Absprache mit Björn zur Zusammenfassung und weiteren Optimierung der NN von Kolja und Felix H.

Schwierigkeiten / offene Fragen:

- Python environment (gelöst)

Eintrag 3 (ca. 8h)


Datum: [19.03.2026]

Titel: [begin Bayesianische Optimierung]

Aus Gruppentreffen: [5]

Arbeitsschritte:

- Zusammenfassung NN Felix H. für mein Vorgehen
 - Konzentration auf Features nach Einfluss auf das Modell (siehe Abbildung Feature importances)



- - durch decisiontree herausgearbeiteter Einfluss der Features bei Bearbeitung berücksichtigen
- Im Sinne der Konvergenzzeit auf die wichtigsten Features zur Beschreibung des Datensatzes nutzen
 - gegebenenfalls einzelne dieser Features zusammenfassen und weiter experimentieren

- Suche nach Optimierung mit grid- und random search
 - Erkenntnis: Felix H. schon sehr viel inklusive ensemble ausprobiert
 - effizientere Suche durch Bayesianische Optimierung
 - Idee dabei: durch geschickte Beobachtung des Lernvorganges abschätzen, ob dieser zielführend ist, oder nicht
 - gegebenenfalls wird nach weniger als der maximalen Epochenzahl abgebrochen, um Rechenzeit zu sparen
- Begin Implimentierung mit Keras tuner model
- Quelle: Luca Invernizzi, James Long, Francois Chollet, Tom O'Malley, Haifeng Jin (2019): Getting started with KerasTuner https://keras.io/keras_tuner/getting_started/
 - [build_tuner_model()] erstellt ein sequenzielles Model über Keras-Paket: "https://keras.io/guides/sequential_model/"
 - zunächst einfaches Modell zur sauberen Implimentierung der Bayes Idee
- direkte Einbindung des Dropout (aus Erkenntnissen der anderen NN)
- im Sinne des vanishing gradient und der gefahr des overfittings zunächst kein sehr tiefes Netz
- zweiter Versuch mit mehr zugelassener Breite (bis 256 Neuronen pro Layer)
- bei NN- Architektur an Erkenntnissen aus 05_Neural_Network_Felix.ipynb orientieren
 - geringe Tiefe, variable Breite
 - start learning rate 0.001
 - Verwendung der vorbereiteten Datenbereinigungen und Skalierungen [load_and_clean_data()]
- Interpretation Residuenhistogramme: (alle ähnliche Verteilung)
- Das Residuendiagramm zeigt eine Zentrierung der Werte um die Nulllinie. Das Modell hat demnach keinen systematischen Bias und unterschätzt Werte ähnlich oft, wie es sie überschätzt. Obgleich der Großteil des Fehlers in einem engen Bereich liegt, zeigt er keine perfekte Normalverteilung, sondern hat "heavy tails". Eine solche leicht Rechtsschiefe Verteilung bedeutet, dass die Preise der Häuser im Zweifel leicht unterschätzt werden. Es sind auch einige Outlier (Residuen>2) zu erkennen deren Preis massiv unterschätzt wurde. Dies könnte an dem Fehlen von Features liegen, welche diese Preissteigungen erklären könnten.

Entscheidungen:

- Pythonumgebung auf 3.10.20 für gute tensorflowpermoance downgraden
- bayesianische Optimierung zunächst einfach mit sequenziellem Modell

Schwierigkeiten / offene Fragen:

- Probleme beim installieren von keras.tuner
 - 1,5h bugfixing und zweifach neues Aufsetzen des Environments
 - downgrade auf python 3.10.20 half

Eintrag 4 (ca. 8h)

Datum: [20.03.2026]

Titel: [fortsetzung Implimentierung Bayesianische Optimierung]

Aus Gruppentreffen: [5]

Arbeitsschritte:

- gestrige Idee weiter implimentiert
- Entscheidung für optimizer adam
 - "generell zunächst basis Einstellungen Nutzen und dann komplexeres ausprobieren"
- Möglichkeit zu hinzufügen eines weiteren Layers einprogrammiert
- Probleme beim einbau des Learning rate Scheduler (*gelöst)
 - nun dynamische Anpassung der learning rate (Standartvorgehen)-> führt zu Performancesteigerung
- Implimentierung des Ensembles. auch zuvor schon deutliche verbesserung gegenüber Einzelmodel
 - Nun sowohl stärkstes Einzelmodell, als auch ensemble der stärksten Modelle im Vergleich
- hinzufügen num_initial_points=5 in tuner
- Hinzufügen "Bedrooms_per_Room" als Feature in eingelesenen Daten
- vorläufig bestes Ergebnis mit R^2 -score= 0.7925 **Entscheidungen:**
- adam optimizer
- weitere Experimente mit Optimizer zu späterem Zeitpunkt
- neues Feature durch hinzufügen: "Bedrooms_per_Room" = "AveBedrms"/"AveRooms"
 - zunächst keine Verbesserung
- Versuch durch erneute Reduktion der Layer und Erhöhung der Breite auf ≤ 512 Neuronen Performance zu erhöhen
 - $R^2 = 0.7897$
- hinzufügen leaky_relu zu möglichen Aktivierungsfunktionen
 - leaky relu setzt Werte <0 im Gegensatz zu Relu nicht auf Null, sodass diese oftmals "absterben" (Dying Relu Problem)
- Werte mit sehr geringer Steigung kommen hie rnoch durch und der Informationsfluss bleibt bestehen
- Schwierigkeiten / offene Fragen:**
- Implimentierung des LR-Scheduler (*gelöst)
- R^2 über 0.8 mit diesen Mitteln erreichbar?
- Verschiebung des Speicherortes hochwertiger Modelle

Erkenntnis:

- alles in allem gleiche performance wie bei random- und grid search mit drastisch reduzierter rechenzeit
- kein besserer R^2 durch hinzufügen eines weiteren features
- ebenfalls keine Verbesserung durch Berücksichtigung Leaky elu
-

Eintrag 5 (ca. 45h)


Datum: [21.03.2026]

Titel: [neue geologische Features]

Aus Gruppentreffen: [5]

Arbeitsschritte: Experiment: Implimentierung der Features 'Lat_x_Lon', 'Dist_to_SF', 'Dist_to_LA'

- Koordinaten in Longitude und Latitude als Kombinations
 - Die Idee dahinter: Aus eigener Erfahrung bekannt, dass LA und SF absolut größte Zentren und entscheidend für Wirtschaft in Kalifornien
 - Eine Orientierung in Abhängigkeit der Distanz zu beiden Zentren könnte helfen Preise exakter zu beschreiben
- Ziel: $R^2 \geq 0.8$ (Berücksichtigung des Loss und der Residuen)
 - Betrachtung darf nie nur im Sinne des R^2 getroffen werden
- Resultat: nach zwei durchläufen keine Erkennbare Verbesserung (Ziel vorest verfehlt)
- Bestes Ergebnis bisher:



Entscheidungen: Keine Blinde Untersuchung mit neuen Features mehr. AEs wird auch mit den neuen features ein random forest zur Untersuchung der feature importance durchgeführt.

Erkenntnis: Auch die Einführung der geografischen Features, bringt keine direkte Verbesserung des Modells hinsichtlich der Konvergenz und

des R^2 -Values. Das impliziert jedoch keine Nutzlosigkeit für das Modell insgesamt, da auch kein Nachteil festgestellt werden kann.

Eintrag 6 (ca. 6h)


Datum: [22.03.2026]

Titel: [Random Forest]

Aus Gruppentreffen: [5]

Arbeitsschritte:

- Wie in Gruppentreffen 5 besprochen Random Forest zur feature importance Analyse
- Random Forest Zelle schreiben
 - `scikit.learn RandomForestRegressor`
 - Zunächst sicherstellen, dass `y_train` richtige size hat
 - Nutzung von `[isinstance()]`
 - `n_jobs=-1` beschleunigt Rechnung durch Nutzung aller zur Verfügung stehender Kerne
 - Skalierung der Daten für Random Forest irrelevant
 - Darstellung der importances durch Balkendiagramm **Erkenntnis:** Untersuchung der Featureimportance (zu sehen auf folgendem Plot:



) zeigt auf, dass population und auch die zuvor etwas vielversprechender wirkende `log_population`, wenig Einfluss auf das NN haben. Es kann davon ausgegangen werden, dass ihr Rauschen die positiven Effekte aufhebt.

Entscheidungen:


- NN ohne Population trainieren **Schwierigkeiten / offene Fragen:**
- Zunächst Fehler der eingesetzten Daten aufgrund deren Umfangs. Gelöst durch erneutes Laden der Daten (manchmal kann es einfach sein)
- Berechnungszeit vor `n_jobs` deutlich länger

Eintrag 7 (ca. 8h)

Datum: 23.03.2026 **Titel:** Interpretation bisheriger Erkenntnisse **Aus Gruppentreffen:** [5]


Arbeitsschritte:

- Die gestrige Entscheidung das NN ohne die Poplationsfeatures zu trainieren, da diese dem Random Forest zur Folge am schwächsten abschneiden, wurde ausgeführt
 - Das ernüchternde Ergebnis: zwar ist das Netz deutlich schneller konvergiert, doch lag der R^2 "nur" noch bei circa 0.783.
- KI Prompt: "Ab welcher Gini Importance lohnt es ein Feature für das Training eines Neuronalen Netzes zu vernachlässigen?"
 - Das Sprachmodell Gemini erklärt, dass bei einer Feature importance von deutlich unter einem Prozent das Rauschen dem Informationsgewinn überwiegt.
 - Aus dem Ergebnissen der Feature Importance analyse (



) folgt, dass einige Features zwar einen relativ geringen, in Summe aber nicht zzu vernachlässigenden Beitrag liefern. Neuronale Netze sind in der Lage auch aus kleinen Signalen Muster zu filtern und profitieren hierbei auch von solceh Signalen, insbesondere wenn es um die letzten Performanceprozent geht.

- Die geringe Hilfe der neuen Features wird auch durch eine Betrachtung der Korrelationsanalyse ersichtlich:



- Besprechung mit Björn
 - Besprechung der bisherigen Ergebnisse
 - Erkenntnisgewinn aus Training der neuronalen Netze ausgetauscht
 - mit Stand der anderen Gruppenmitglieder verglichen
 - Aufteilung des weiteren Vorgehens
 - Wer fasst welches Notebook zusammen?
 - Besprechung der Ergebnisse bei Gruppentreffen am 26.03
- Implimentierung einer Latex Arbeitsumgebung in VS-Code
 - installation der notwendigen Pakete
 - einarbeiten in die Tau-class
 - Modifikation des Gitignore
- Weitere Durchläufe unter Variation der Umfänge für die Hyperparamter durchgeführt...
 - keine Nennenswerten Veränderungen gefunden
 - Ensembleperformance relativ konstant

- Random Forest liefert minimal bessere Ergebnisse als NN (Diff. $R^2 = 0.0044$).
 - Erklärungsansatz: Tabellarische Daten mit Unregelmässigkeiten, harten Kanten und schiefen Verteilungen lassen sich oft mit Entscheidungsbaum beschreiben. Neuronale Netze performen besser auf "glatten" Daten / Normalverteilungen.
 - Lösungsansätze:
 - Noch weiter Verbesserte Datenaufbereitung. Beispielweise Versuch weitere Ausreißer an der Definitionsgrenze heraus zu filtern.
 - Statt Standard-scaler oder MinMax-Scaler Powertransformer nutzen
 - Powertransformer ist stärker auf schiefen Datenverteilungen wie zum Beispiel bei MedInc und Population als StandardScaler.
 - Die Anwendung eines Powertransformer wird insbesondere für den Kaliforniahousing Datensatz empfohlen.
 - Yeo, I. K., & Johnson, R. A. (2000). A new family of power transformations to improve normality or symmetry. Biometrika, 87(4), 954-959
 - Kuhn, M., & Johnson, K. (2013). Applied Predictive Modeling. Springer. (Kapitel 3: Data Pre-processing)
 - Deshalb random Forest auch im Vorteil, da dieser unbeeinflusst von schiefen Datenverteilungen bleibt.
 - ein PowerTransformer wie er beispielsweise in Scikit learn enthalten ist, behebt das Problem mit der Schiefe und könnte zum Schluß mit dem Random Forest führen
 - Batch size variieren:
 - eine größere Batchsize führt zu ruhigerem Training, aber auch zu Overfitting. Aufpassen!

Erkenntnis:

- Eine Beschneidung der Features ist zunächst nicht ratsam und führt zu Performanceminderung.
- Letzlich haben sich die neuen Featureideen als nicht nützlich herausgestellt.
- Latex in VSCode zu implementieren ist nicht ganz einfach

Entscheidungen:

- Implementation des Powertransformer zunächst überspringen

Schwierigkeiten / offene Fragen:

- Kann durch Featureoptimierung das Neuronale Netz mit meinen Parametermöglichkeiten über $R^2 = 0.8$ steigen?
- Schwierigkeiten Latex auf VS-Code zum laufen zu bringen
- ständig neues Auftauchen der Latexhilfsdateien in gitchanges trotz gitignore
- noch unklar, ob Zeitaufwand für Powertransformer lohnenswert

Eintrag 8 *circa: 8h*

Datum: 24.02.2026 **Titel:** Dokumentation **Aus Gruppentreffen:** [5]

Arbeitsschritte:

- bemerkt, dass ich durch gitignore einige Daten aus dem Git geworfen habe die noch benötigt werden
 - noch viel Verständnis nötig...
 - Überlegung ob betreffende Dateien neu pushen, oder Versuchen auf alte Gitversion zurück zu gehen
- Nach Überlegungen von gestern Versuche ich nun durch Variation der Batchsize das Ergebnis noch weiter zu pushen
 - Testen mit Batchsize = 128
 - Nach langer Rechenzeit: $R^2 = 0.7922$
 - Fazit: Wie bereits in 05_Neural_Network_Felix.ipynb festgestellt, hilft eine größere Batchsize nicht weiter.
 - Weiterhin mit Batchsize 32 arbeiten.
- Zusammenfassungen geschrieben:
 - 01_LASSO_Ridge
 - 02_Decision_Tree
 - 03_Ensemble
 - 04_kNN_Regression geschrieben
- Saubere Dokumentation des Notebooks
- Ausarbeitung des Modellaufrufs mit Ausgabe der erreichten Werte
- Analyse der Werte im Kontext lineare Regression (weit übertroffen), aber auch Random Forest Modellen (nicht ganz erreicht).
- Bugfix der [build_tuner_modell]-Funktion (dennoch muss vor Ausführung der nachfolgenden Zellen auf Initialisierung des Tuner gewartet werden)
-

Schwierigkeiten / offene Fragen:

- Fehlermeldung: "notebook controller is DISPOSED"
 - Versuch Kernel Restart, VS-code neustart -> Hilft vorerst
- versehentlich Dateien gelöscht, durch Hilfe von Flo aus Repo wieder gerettet

Eintrag 9 (ca. 7h)

Datum: 25.03.2026

Titel: Ergebnisse der Gruppe zusammentragen **Aus Gruppentreffen:** 5

Arbeitsschritte: Vergleich mit linearer Regression zu NN hinzugefügt. Wie in Gruppentreffen vereinbart:

- Lesen aller Notebooks
- Zusammenfassen der Neuroanalalen Netzwerk Notebooks
 - zunächst "Schmierzettel in Word"
 - jedes Neuronale Netz durchgegangen

- Ergebnisse und Gedanken zusammengetragen
- Begin schreiben der Ergebnis PDF
- weitere Latex Einstellungen
- Auseinandersetzung mit den Fähigkeiten der Tau-Class als mächtige Latexvorlage
- Zusammenfassung der nuller Notebooks von Björn leicht überarbeitet **Erkenntnis:**
- Für Latex ist Textstudios deutlich intuitiver als VS-Code.
-

Entscheidungen:

- einzelne Abschnitte zu den bearbeiteten Parametern unter Zusammenfassung der Erkenntnisse der Gruppenmitglieder anstatt einfaches Herunterarbeiten der Notebooks

Schwierigkeiten / offene Fragen: Zunächst scheinbare Widersprüche in den Ergebnissen der Featureanalyse bezüglich der Sinnhaftigkeit des [lr_schueele].

- einzelne Betrachtung unter festhalten der restlichen Parameter ergab keine nennenswerte Verbesserung
- Es ist jedoch davon auszugehen, dass Simultanoptimierung der Hyperparameter durchaus profitiert
-

Eintrag 10 (ca. 9h)


Datum: 26.03.2026

Titel: Gruppenergebnisse niederschreiben **Aus Gruppentreffen:** 5

Arbeitsschritte:

- Schreiben des Absatzes zur Explorativen Datenanalyse
 - zunächst Schwierigkeiten beim Einfügen einer Grafik (gelöst)
 - Aufteilung in Analyse, Bereinigung und Darstellung der Daten
- Lineare Regression
 - Baseline erklärt und Fehlerwerte und R^2 als Vergleich für spätere Modelle
 - LASSO und Ridge
- Decision Tree, Ensemble und K-Nearest neighbor als weiterer Vergleich und Messlatte für mögliche Performance erhalten jeweils eigenen Absatz
- Neuronale Netze
 - Vorgehen und Aufteilung erklärt
 - Ansätze zur Verbesserung des Neuronalen Netzes unter den Überthemen "Architektur" und "Featureengineering".
 - Architektur umfasst:
 - Layer
 - Regularisierung

- Aktivierungsfunktionen
- Hyperparameter
- Featureengineering beinhaltet die geschickte Wahl der richtigen für das training und Versuche der Neuschaffung von Parametern
- Absatz lineare Regression vs. Neuronale Netze - besonders viel Aufwand hinein stecken
- stellt sich heraus ich habe das stärkste Modell geschaffen
- (



)

- Vorbereitung auf Gruppentreffen
 - Fragen bezüglich der Zusammenfassung der Ergebnisse an die Gruppenmitglieder
- Gruppentreffen 6 (siehe Bericht GT &6)
 - persönliche Aufgaben:
 - fertig schreiben der Ergebnisse
 - hinzufügen der Personen die den jeweiligen Abschnitt bearbeitet haben
 - zusammen mit Björn Zusammenfassung der Gruppentreffen

- Formatierungen geklärt **Erkenntnis:**
 - Eine saubere Ergebnis PDF schreiben ist deutlich aufwendiger als erwartet

Schwierigkeiten / offene Fragen:

- git merge crash
 - Ständige Probleme durch ID Änderung durch ausführen des Codes anderer und pushen der ID-Änderung.
 - vorläufiger Fix kostet mich eine 1.5h, viele Nerven, aber hoffentlich keine Änderung an dem betroffenen Notebook
 - Tau class template bietet viele Möglichkeiten, hat aber auch sehr viele Schwierigkeiten mit denen es umzugehen gilt.->laufend neue Entdeckungen
 -
-

Eintrag 11 (ca. 9h)

Datum: 27.03.2026

Titel: Gruppenergebnisse niederschreiben **Aus Gruppentreffen:** 6

Arbeitsschritte:

- Hinzufügen der Namen der Gruppenmitglieder
- Einfügen von passenden Grafiken in Ergebnis Report (=ER)
- Kommentieren dieser Grafiken
- Rechtschreibkorrektur
- erneutes Korrekturlesen
- Referenzieren
- Zusammenfassung der Gruppentreffen mit Björn zsm abgabefertig gemacht
- Zusammenfassung dieses Logbuchs
 - generieren von Grafiken passend zu den Inhalten
 - ebenfalls mit Rechtschreibkorrektur
 - Bibliothek mit Referenzen aufbauen
 - Markdowndatei "Logbuch_Felix_Neumann" als Pdf exportiert und angehängt.
- erneutes Ausführen des Codes
- Titelseite vorbereitet und angehängt
- restliche Zeit mit Anhängen, zippen und hochladen **Erkenntnis:**
 - neues gelernt über Referenzierung in Latex
 - ich mache zu viele Rechtschreibfehler

Entscheidungen:

- 10 Finger schreiben lernen
- Markdownnin Latex anhängen

Schwierigkeiten / offene Fragen:

- ordentliches Verpacken aller Bestandteile
 - Rechtschreibkorrektur
-