

Gruppennummer: 308

Neuronales Netz für den kalifornischen Hauspreis-Datensatz

Portfolio von:

Florian Adamczyk
Matrikelnummer: 8105234

Rolle im Projekt:

Vorarbeit, Infrastruktur, EDA, Baseline, Kern-Notebook NN

Gruppenmitglieder:

Björn Becker
Felix Hollfoth
Felix Neumann (Sprecher)
Kolja Scriba

Projektfokus:

California Housing, klassische Verfahren und neuronale Netze

Modul: Künstliche Intelligenz I
Dozenten: Prof. Dr. Christian Heiliger, Dr. Jan-Matthis Waack
Semester: Wintersemester 2025/26
Abgabetermin: 15.04.2026

Neuronales Netz für den kalifornischen Hauspreis-Datensatz

Florian Adamczyk^a^aJustus-Liebig-Universität Gießen, Matrikelnummer 8105234

Gruppe 308 – KI I Projekt WS 2025/26

Zusammenfassung—Diese Zusammenfassung dokumentiert meinen konkreten Beitrag zum KI I-Projekt zur Vorhersage von Hauspreisen im California-Housing-Datensatz. Der Schwerpunkt liegt auf der Vorarbeit, ohne die die anschließende Gruppenarbeit nicht reproduzierbar gewesen wäre: Repository-Initialisierung, Umgebungsmanagement, gemeinsame Python-Hilfsfunktionen, einheitliche Metriken, standardisierte Plots und der Einstieg in die Modellierung.

Der Arbeitsumfang in der ersten Version war inzwischen veraltet, weil das Logbuch später noch deutlich erweitert wurde. Diese Fassung aktualisiert den Umfang und zeigt deshalb nicht nur das späte neuronale Netz, sondern auch die methodischen Grundsteine: EDA, Baseline, Regularisierung, Entscheidungsbaum, kNN, Ensemble-Modelle und die Hyperparameterarbeit rund um das Neuronale Netz.

Mein bestes neuronales Netz erreicht auf dem Testset einen R^2 -Wert von 0,7795 und liegt damit klar über der linearen Regression mit 0,6326. Entscheidend war dabei nicht nur das Modell selbst, sondern die saubere technische Grundlage, auf der die gesamte Gruppe arbeiten konnte.

Keywords—California Housing, Neuronales Netz, TensorFlow, Regression, Git, Reproduzierbarkeit

1. FRAGESTELLUNG UND EIGENER BEITRAG

Ziel des Projekts war es, den California-Housing-Datensatz so aufzubereiten und zu modellieren, dass die Vorhersage von `MedHouseVal` nicht nur mit klassischen Verfahren, sondern auch mit einem neuronalen Netz sinnvoll eingeordnet werden kann [4, 6]. Meine Rolle war dabei bewusst früh und technisch grundlegend: Ich habe das Repository initialisiert, die gemeinsame Umgebung vorbereitet, die Projektstruktur dokumentiert und die Basiskomponenten gebaut, auf denen die spätere Gruppenarbeit aufsetzt.

Im Gegensatz zu reiner Modelloptimierung war mein Beitrag vor allem ein Reproduzierbarkeitsbeitrag. Ohne einheitlichen Daten-Split, konsistente Metriken, gemeinsame Plots und eine saubere Git-/Notebook-Disziplin wären die Ergebnisse der verschiedenen Teammitglieder kaum direkt vergleichbar gewesen. Genau deshalb ist diese Vorarbeit fachlich relevant und nicht nur organisatorisch.

Tabelle 1. Meine Hauptbeiträge im Projektverlauf

Bereich	Inhalt
Repository/Setup	Git-Initialisierung, erste Struktur, nbstripout, VS-Code-Unterstützung
Dokumentation	README, Ressourcen, Masterplan, Aufgabenübersicht, Meeting-Vorlagen
Python-Basis	requirements.txt, kompatible Umgebung, gemeinsames <code>utils/</code>
Daten/Plots	Laden, Cleaning, Split, Metriken, Standardplots, Export nach <code>results/</code>
Modelle	EDA, lineare Baseline, LASSO/Ridge, Decision Tree, kNN, NN

2. WARUM DIE VORARBEIT ZENTRAL WAR

Die eigentliche Leistung meines Beitrags liegt darin, dass alle weiteren Notebooks auf derselben technischen Basis arbeiten konnten. Das betrifft drei Dinge besonders stark: denselben bereinigten Datensatz, dieselbe Trennung in Train und Test und dieselben Metriken. Dadurch sind Unterschiede zwischen Modellen nicht zufällig durch verschiedene Splits oder unterschiedliche Auswertelogik verfälscht.

Zusätzlich war die Arbeit an README, Anforderungen und Team-Support wichtig, weil es für viele im Team das erste Projekt in dieser

Umgebung war. Ich habe deshalb nicht nur Code geschrieben, sondern auch die Einstiegshürde für die anderen reduziert: klare Struktur, laufende Umgebung, reproduzierbare Notebook-Workflows und Hilfe bei Git und VS Code.

Verwendete Hilfsmodule in `utils/`

Die von mir geschriebenen Kernmodule waren `utils/data.py`, `utils/evaluation.py` und `utils/plotting.py`. Zusammen bilden sie die Infrastruktur, die alle weiteren Notebooks genutzt haben.

`data.py`

- `load_raw_data`: California-Housing-Datensatz als `DataFrame` laden.
- `clean_data`: Cut-offs entfernen und Ausreißer über das 98%-Quantil filtern.
- `load_and_clean_data`: Laden und Bereinigen in einem Schritt.
- `get_train_test_split`: Einheitlichen 80/20-Split erzeugen, optional skalieren.

`evaluation.py`

- `evaluate_model`: R^2 , MAE und RMSE für Train und Test berechnen.
- `evaluate_predictions`: Dasselbe direkt aus Vorhersagen, z. B. für Keras-Modelle.
- `evaluate_test_predictions`: Kompakte Testauswertung für Modelle mit nur Test-Output.
- `add_result`: Ergebnis in die gemeinsame Vergleichsliste schreiben.
- `compare_models`: Vergleichstabelle aller Modelle erstellen und sortieren.
- `reset_results`: Ergebnisliste zurücksetzen.

`plotting.py`

- `save_fig`: Einheitlicher Export als PNG und PDF nach `results/`.
- `plot_predicted_vs_actual`: Soll-Ist-Streudiagramm mit Ideallinie.
- `plot_residuals`: Residuen gegen Vorhersage.
- `plot_feature_importances`: Wichtige Features geordnet darstellen.
- `plot_correlation_heatmap`: Korrelationsmatrix als Heatmap.
- `plot_histograms`: Histogramme aller Merkmale in einem Raster.
- `plot_features_vs_target`: Scatterplots aller Features gegen `MedHouseVal`.

Diese Vorarbeit war für die Gruppe entscheidend, weil sie nicht nur Zeit gespart hat, sondern die gemeinsame Aussagekraft aller Experimente erst hergestellt hat. Modelle sind nur dann wirklich vergleichbar, wenn Datenaufbereitung, Split und Bewertung identisch sind.

Weitere Beiträge im Projektverlauf

Neben der technischen Basis habe ich im Projektverlauf weitere Aufgaben übernommen. Dazu gehörten die laufende Betreuung des Repositories, die Unterstützung bei Git-Konflikten im Team, die Ausarbeitung von Vorlagen für Gruppentreffen, die Pflege der Abhängigkeiten in `requirements.txt` und später die Bereitstellung eines gemeinsamen Tau-Templates für die Portfolio-Summarys.

Ein weiterer wichtiger Schritt war am Ende die bewusste Entscheidung, `nbstripout` temporär zu deaktivieren und die Notebooks mit gespeicherten Outputs zu committen, damit die Korrektur direkt alle Ergebnisse, Kurven und Metriken sehen kann [5]. Genau dieser Wechsel zwischen sauberer Entwicklungshistorie und transparenter Abgabe war Teil meiner Koordinationsarbeit.

Die Logbuch-Einträge zeigen außerdem, dass diese Vorarbeit aus konkreten technischen Arbeitspaketen bestand: Am 11.02. habe ich nach dem ersten Gruppentreffen den Notebook-Git-Workflow recherchiert, `nbstripout` praktisch getestet und die zentrale Ressourcen-Dokumentation aufgebaut. Am 17.02. folgte die technische Konsolidierung mit `.gitattributes`, Aufräumen früherer Repo-Artefakte und

Stabilisierung der gemeinsamen Struktur. Genau diese frühe Standardisierung hat in der Folge Setup-Zeit und Merge-Probleme im Team reduziert.

3. DATENBASIS UND EXPLORATIVE ANALYSE

Zu Beginn habe ich die Rohdaten untersucht, um die Struktur des Datensatzes zu verstehen und die spätere Bereinigung nachvollziehbar zu machen. Besonders wichtig waren die bekannten Cut-offs bei MedHouseVal und HouseAge sowie die starken Ausreißer in AveRooms, AveBedrms, Population und AveOccup. Genau diese Schritte wurden später in `utils/data.py` zentralisiert.




Abbildung 1. Vorher-Nachher-Vergleich der Verteilungen aller Kernmerkmale. Links (raw) erkennt man die Probleme des Rohdatensatzes: harte Deckelungen und starke Rechtsschiefe, insbesondere bei AveRooms, AveBedrms, Population und AveOccup. Rechts (clean) ist nach den von mir implementierten Bereinigungsverfahren (Cut-off-Behandlung und Quantilfilter) eine deutlich stabilere Verteilungsstruktur sichtbar. Diese Gegenüberstellung macht den Effekt meiner Vorarbeit direkt sichtbar: Die nachfolgenden Modelle werden weniger von Extremwerten dominiert und auf konsistenteren Eingaben trainiert.




Abbildung 2. Korrelationsmatrix der bereinigten Merkmale. Besonders klar ist der starke Zusammenhang zwischen MedInc und MedHouseVal; zugleich zeigen die weiteren Korrelationen, dass das Problem nicht rein eindimensional ist.

Die EDA war kein Selbstzweck. Sie hat direkt die Modellwahl vorbereitet: lineare Verfahren als Baseline, Regularisierung wegen Korrelationen, nichtlineare Verfahren wegen der sichtbaren Struktur und später auch geographische und abgeleitete Merkmale. Die Plots zeigen außerdem, warum das Problem nicht nur durch ein einzelnes lineares Signal erklärt werden kann.

4. VON DER BASELINE ZU KLASSISCHEN MODELEN

Die lineare Regression war die erste belastbare Referenz. Sie hat als Minimum dienen sollen, gegen das alle weiteren Modelle gemessen werden. Der Residuenplot zeigt allerdings systematische Muster: Das Modell unterschätzt in bestimmten Preisbereichen und bildet komplexe Strukturen nur teilweise ab.




Abbildung 3. Baseline mit linearer Regression: Residuenplot auf dem Testset. Die erkennbaren systematischen Fehler zeigen, dass der Datensatz nicht rein linear ist und dass eine flexiblere Modellklasse nötig ist.

Darauf aufbauend habe ich die klassischen Verfahren mit vorbereitet oder ausgewertet:

- **LASSO/Ridge:** Regularisierung und Skalierung wurden verglichen. Die gemeinsame Aussage war, dass Regularisierung hilft, aber allein noch kein vollständig nichtlineares Problem löst.

- **Decision Tree:** Der Baum lieferte eine anschauliche Interpretation, aber auch deutliches Overfitting bei zu großer Tiefe.
- **kNN:** Dieses Modell reagierte stark auf die Skalierung und auf die Wahl von k ; es war ein gutes Beispiel dafür, wie wichtig die Vorverarbeitung ist.
- **Ensemble-Modelle:** Random Forest und Gradient Boosting zeigten im Vergleich zu den Baselines klar bessere Vorhersagen und lieferten gleichzeitig nützliche Feature-Importances.




Abbildung 4. Decision-Tree-Tiefen-Tuning mit Train- und Test- R^2 . Die Kurven zeigen den typischen Verlauf: zunächst steigt die Modellgüte, bei zu großer Tiefe dominiert jedoch Overfitting.




Abbildung 5. kNN-Regression: Einfluss von k auf die Modellgüte. Kleine Nachbarschaften überfitten, größere Werte glätten zu stark; ein mittlerer Bereich liefert die robusteste Generalisierung.




Abbildung 6. Vergleich der Ensemble-Modelle als starke nichtlineare Referenz. Die Ergebnisse zeigen, dass robuste Baum-Ensembles nah an die besten NN-Ergebnisse heranreichen.

Die klassische Modellierung war für mich vor allem methodische Vorbereitung auf das neuronale Netz: Ich habe gesehen, wo einfache Modelle an ihre Grenzen kommen, welche Features stark tragen

und wo Skalierung oder Regularisierung wirklich einen Unterschied machen.

5. NEURONALES NETZ UND HYPERPARAMETERARBEIT

Das Kernstück meines späteren Beitrags ist das Notebook `05_Neural_Network_Florian.ipynb`. Dort habe ich die Modellarchitektur schrittweise aufgebaut, von kleinen Netzen bis zu tieferen Varianten mit Dropout. Die zentralen Lernkurven zeigen, dass tiefere Modelle das Trainingsproblem deutlich besser lösen, aber zugleich die Gefahr des Overfittings steigt.




Abbildung 7. Direkter Vergleich des besten neuronalen Netzes gegen die lineare Regression. Das beste Netz erreicht auf dem Testset $R^2 = 0,7795$ und verbessert die Baseline damit deutlich.

Tabelle 2. Detaillierte Entwicklung der NN-Architekturen (Notebook Florian)

Modell	R^2 Train	R^2 Test
Lineare Regression	0.6465	0.6326
NN [32]	0.7555	0.7427
NN [64,32,16]	0.8200	0.7393
NN [128,64,32]	0.8804	0.7171
NN [128,64,32,16]+Dropout	0.8272	0.7525
Bestes Ergebnis (Summary)	–	0.7795

Die Tabelle zeigt den Kernpunkt meiner NN-Arbeit: Mit steigender Modellkapazität steigt zunächst die Leistung, aber ohne Regularisierung kippt das Modell in Overfitting. Genau hier war Dropout entscheidend. Modell 3 erzielt einen sehr hohen Trainingsscore, verliert aber deutlich auf dem Testset; das tiefere Modell mit Dropout generalisiert stabiler und liefert die bessere praktische Modellgüte.

Das Ergebnis ist nicht nur numerisch besser, sondern auch inhaltlich plausibel: Der California-Housing-Datensatz enthält nichtlineare Abhängigkeiten, regionale Muster und Wechselwirkungen, die eine lineare Regression nur unvollständig erfasst. Das NN kann diese Muster besser modellieren, braucht dafür aber mehr Aufwand bei Architektur und Tuning [3, 7, 8].




Abbildung 8. Hyperparameteranalyse des NN. Vor allem Dropout, Lernrate und L2-Regularisierung haben einen deutlichen Einfluss; reines Nachjustieren einzelner Parameter reicht daher nicht aus.




Abbildung 9. Lernkurven der getesteten NN-Architekturen (Train/Validation) über die Epochen. Man sieht, dass größere Modelle den Trainingsfehler schneller reduzieren, sich die Validierung aber je nach Architektur unterschiedlich stabil entwickelt. Genau aus diesem Verlauf folgt meine zentrale Tuning-Entscheidung: Nicht nur mehr Tiefe, sondern kontrollierte Regularisierung (insbesondere Dropout) ist notwendig, um hohe Trainingsgüte in robuste Testleistung zu überführen.

In der Summe ist mein Eindruck klar: Das beste Modell entsteht nicht durch einen einzigen cleveren Layer, sondern durch saubere Datenbasis, stabile Evaluation, kontrollierte Regularisierung und systematisches Tuning. Genau deshalb war die frühe Infrastrukturarbeit so wichtig.

6. KONKRETE ERGEBNISSE UND EINORDNUNG

Die wichtigsten quantitativen Eckpunkte meines Beitrags sind:

- Lineare Regression als Baseline: $R^2_{Test} \approx 0,6326$.
- Bestes neuronales Netz: $R^2_{Test} = 0,7795$.
- Verbesserung gegenüber der Baseline: rund 15 Prozentpunkte beim Test- R^2 .
- Zusätzlich sichtbar besseres Fehlerverhalten im Residuenbild und in der Vorhersage gegen den Ist-Wert.

Im Vergleich zu den klassischen Methoden war mein NN klar über der linearen Baseline und auch über den meisten nichtlinearen Standardmodellen aus den Grundnotebooks. Decision-Tree-Tuning liegt sichtbar unter meinem besten NN, kNN ist solide, aber ebenfalls niedriger. Ensemble-Methoden kommen nah an NN-Leistung heran; in späteren Kombinationen wurden Werte im Bereich knapp unter bzw. um 0.79 sichtbar. Damit war mein NN-Modell in der Praxis konkurrenzfähig zu den starken klassischen Verfahren [1, 2].

Auch für die Teamarbeit war mein Beitrag relevant, weil ich die Umgebung und die Arbeitsweise für alle anderen mit vorbereitet habe:

- Ich habe README.md und requirements.txt so aufgebaut, dass neue Teammitglieder schneller starten konnten.
- Ich habe nbstripout und Git-Hooks thematisiert, damit Notebook-Outputs nicht die Versionsgeschichte verunreinigen.

- Ich habe Notebook-Vorlagen und Meeting-Vorlagen mit vorbereitet, damit die Gruppentreffen strukturierter dokumentiert werden konnten.
- Ich habe mehrfach bei Git- und VS-Code-Fragen geholfen, weil für viele im Team dies die erste Arbeit in dieser Umgebung war.

Bewertung der Arbeit

Mein eigener Beitrag lag damit weniger in einem einzelnen Modell als in einer belastbaren Kette von Entscheidungen: gute Datenbasis, saubere Werkzeuge, reproduzierbare Auswertung und erst darauf aufbauend Modellierung. Genau diese Reihenfolge ist fachlich wichtig, weil sie verhindert, dass zufällige Effekte als Fortschritt missverstanden werden.

7. EINSCHÄTZUNG DER GRUPPENMITGLIEDER

Gemäß Aufgabenstellung benenne ich für jedes Gruppenmitglied jeweils mindestens eine Stärke und eine Schwäche, mit Fokus auf Zusammenarbeit, Arbeitsweise und Kommunikation.

Kolja Scriba

Stärke: Kolja war besonders am Anfang des Projekts sehr aktiv und hat früh produktive Beiträge geliefert. Die Abstimmung mit ihm lief sehr schnell und unkompliziert, vor allem über WhatsApp, was die gemeinsame Planung deutlich erleichtert hat.

Schwäche: Durch den Umzug war seine verfügbare Zeit später eingeschränkter, was die Kontinuität einzelner Aufgabenphasen erschwert hat. Zusätzlich gab es zeitweise technische Reibung durch das Macbook-Setup.

Björn Becker

Stärke: Björn hat in der Endphase mit hoher Intensität gearbeitet und insbesondere bei Hyperparameter-Suchen, Iterationen und Ergebnisaufbereitung viel eingebracht. Seine späte Phase war inhaltlich stark und gut dokumentiert.

Schwäche: Wegen Klausuren war sein aktiver Einstieg später als bei den anderen. Dadurch mussten einige Grundlagen zuerst nachgezogen werden, bevor er voll in die Modellarbeit einsteigen konnte.

Felix Hollfoth

Stärke: Felix H. hatte sehr viel fachliche Sicherheit bei neuronalen Netzen und konnte viele inhaltliche Impulse geben, etwa bei Random Search, Feature-Selektion und Lernratenstrategien.

Schwäche: Durch den hohen inhaltlichen Anspruch waren seine Arbeiten teils schwerer für alle Teammitglieder sofort anschlussfähig. Für die Gruppe bedeutete das zusätzlichen Abstimmungsbedarf in der Übergabe.

Felix Neumann (Sprecher)

Stärke: Felix N. hat als Sprecher die Organisation in der Schlussphase sehr zuverlässig getragen und die Abgabewege, Terminfragen und Konsolidierung sauber koordiniert.

Schwäche: Auch bei ihm gab es durch das Macbook-Setup zeitweise technische Hürden im Umfeld TensorFlow/Python-Versionen, was punktuell Zusatzaufwand in der Abstimmung erzeugte.

Selbsteinschätzung (Florian Adamczyk)

Stärke: Ich habe die Vorarbeit früh und umfassend übernommen und damit den technischen Unterbau geliefert, auf dem die gesamte Modellarbeit aufbauen konnte. Dazu kamen schneller Support bei Git/VS Code sowie hohe Erreichbarkeit für Abstimmungen.

Schwäche: Weil ich viel Infrastruktur- und Supportarbeit gemacht habe, blieb weniger Zeit für tiefes eigenes Hyperparameter-Tuning in der allerletzten Phase als in einem reinen Einzelprojekt möglich gewesen wäre.

ANHANG: LOGBUCH

Das vollständige Logbuch ist als Pflichtanhang beigefügt und dokumentiert die Arbeitsschritte chronologisch.

8. FAZIT

Ich sehe meinen Beitrag als die technische und methodische Grundlage des Projekts. Die spätere Modellarbeit der Gruppe konnte nur deshalb sinnvoll verglichen werden, weil ich die Vorarbeit auf einheitliche Daten, Metriken, Plots und Projektstruktur ausgerichtet habe. Gleichzeitig habe ich mit dem eigenen NN-Notebook gezeigt, dass sich der California-Housing-Datensatz mit einem gut regularisierten Netz deutlich besser modellieren lässt als mit einer linearen Regression.

Die wichtigste Schlussfolgerung ist deshalb zweistufig: Erstens ist die Vorarbeit kein Nebenprodukt, sondern Voraussetzung für belastbare Ergebnisse. Zweitens ist das neuronale Netz im Projekt nicht nur "das letzte Modell", sondern der methodische Abschluss einer sauberen Modellkette, die bei EDA und Baseline beginnt.

QUELLEN UND HILFSMITTEL

Die externen Quellen werden im Fließtext mit `\cite{...}` referenziert und nachfolgend vollständig dokumentiert. Als Entwicklungs- und Analysewerkzeuge wurden insbesondere Python, TensorFlow/Keras, scikit-learn, pandas, numpy, matplotlib, seaborn, Jupyter und VS Code eingesetzt. Der Umgang mit Notebook-Outputs im Git-Workflow wurde mit nbstripout organisiert [5].

Der Einsatz generativer KI erfolgte unterstützend für Strukturfeedback, sprachliche Straffung und Formulierungsalternativen; die inhaltlichen Aussagen, Metriken, Tabellenwerte und Abbildungsinterpretationen stammen aus den eigenen Notebooks und Resultatdateien.

- [1] J. Bergstra und Y. Bengio, „Random Search for Hyper-Parameter Optimization“, *Journal of Machine Learning Research*, Jg. 13, S. 281–305, 2012.
- [2] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever und R. Salakhutdinov, „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“, *Journal of Machine Learning Research*, Jg. 15, S. 1929–1958, 2014.
- [3] S. Russell und P. Norvig, *Artificial Intelligence: A Modern Approach*, 4. Aufl. Pearson, 2021.
- [4] C. Heiliger und J.-M. Waack, *Projekt WS 2025/26 K"unstliche Intelligenz I – Aufgabenstellung Gruppe 308*, JLU Gießen, Version vom 03.02.2026, 2026.
- [5] Kynan. „nbstripout – Strip output from Jupyter notebooks“, besucht am 10. Apr. 2026. Adresse: <https://github.com/kynan/nbstripout>
- [6] scikit-learn developers. „California Housing Dataset (fetch_california_housing)“, besucht am 10. Apr. 2026. Adresse: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.fetch_california_housing.html
- [7] scikit-learn developers. „Model Evaluation: R2, MAE, RMSE“, besucht am 10. Apr. 2026. Adresse: https://scikit-learn.org/stable/modules/model_evaluation.html
- [8] TensorFlow Team. „TensorFlow Installation and Keras Regression Guide“, besucht am 10. Apr. 2026. Adresse: <https://www.tensorflow.org/install/pip>

Logbuch – Florian Adamczyk

Matrikelnummer: 8105234

Kurs: KI 1 – Projekt, WS 2025/26

Gruppe: 308

Eintrag 1 – Recherche: Git-Workflow & nbstripout

Datum: 11.02.2026

Zeitraum: ca. 16:00 – 20:00 Uhr (Selbststudium, im Anschluss an Gruppentreffen 1)

Gesamtzeit: ca. 4 h

Arbeitsschritte

- Im Gruppentreffen 1 (11.02.) wurde u. a. die Nutzung von Git/GitHub beschlossen. Im Anschluss habe ich eigenständig recherchiert, wie man Jupyter Notebooks sinnvoll versionieren kann. (*ca. 30 min*)
- **Problem identifiziert:** Notebook-Outputs und Metadaten erzeugen unnötige Merge-Konflikte und erschweren Code-Reviews erheblich. Lektüre von Blogposts und Stack-Overflow-Threads zu Jupyter + Git. (*ca. 45 min*)
- **Lösung gefunden:** **nbstripout** — ein Tool, das Zell-Outputs automatisch vor jedem Commit entfernt (Git-Hook). Offizielle Dokumentation und GitHub-Repo gelesen, mehrere Alternativen verglichen (**nbconvert --clear-output**, manuelle Pre-Commit-Hooks). (*ca. 45 min*)
- GitHub-Repository initial eingerichtet (**git init**, Remote angelegt, README aus dem GitLab-Kursrepo übernommen). (*ca. 30 min*)
- **nbstripout** lokal installiert und als Git-Hook ausprobiert; initialer Test-commit mit einem Notebook erstellt und Diff auf saubere Ausgabe geprüft. (*ca. 30 min*)
- Dokumentation in **Ressources.md** erstellt: Installationsanleitung, Einrichtung als Git-Hook, Links zu den relevanten Repositories (Arbeitsrepo, Kurs-GitLab, Vorlesungsfolien, Lösungen). (*ca. 60 min*)

Entscheidungen

Entscheidung	Begründung
nbstripout als verpflichtender Git-Hook	Vermeidet Merge-Konflikte durch Notebook-Outputs
Zentrale Dokumentation in Ressources.md	Alle Teammitglieder können Installationsschritte dort nachschlagen

Schwierigkeiten

- Keine direkten Schwierigkeiten; die Recherche war erfolgreich.
-

Eintrag 2 – Erste Repository-Strukturierung

Datum: 17.02.2026

Zeitraum: Im Anschluss an Gruppentreffen 2, ca. 3 h

Gesamtzeit: ca. 3 h

Arbeitsschritte

- Wie am Gruppentreffen 2 am 17.02. besprochen: **nbstripout** im Team als Standard vorgestellt; Fragen der anderen Teammitglieder zur Installation beantwortet. (*ca. 30 min*)
- PDFs/-Ordner im Repository angelegt, Aufgabenstellung (PDF) heruntergeladen und eingecheckt. (*ca. 20 min*)
- Alte Test-Dateien und überflüssige Artefakte aus der initialen Repository-Einrichtung aufgeräumt (Branches bereinigt, überflüssige Commits analysiert). (*ca. 45 min*)
- **.gitattributes** konfiguriert, um Notebooks korrekt mit **nbstripout** zu behandeln; Konfiguration durch einen Test-Commit verifiziert. (*ca. 45 min*)
- **Meine Aufgabe bis zum nächsten Treffen** (wie am Gruppentreffen besprochen): Datenbereinigung und Datenanalyse gemeinsam mit Kolja — erste Planung der Vorgehensweise notiert. (*ca. 40 min*)

Schwierigkeiten

- Keine nennenswerten Probleme.
-

Eintrag 3 – Projektstruktur, Utils-Modul, Notebooks & erste Modelle

Datum: 20.02.2026

Zeitraum: ca. 07:00 – 22:00 Uhr (ganztägig, inkl. Gruppentreffen 3 von 9:00–11:30 Uhr)

Gesamtzeit: ca. 35 h (*verteilt auf 20.02. und nachfolgende Abende bis 25.02.*)

Dies war der zentrale Arbeitsblock, in dem ich die gesamte Projektgrundstruktur aufgebaut habe. Ausgangspunkt waren die Aufgaben, die am Gruppentreffen 2 (17.02.) vereinbart wurden: Datenbereinigung und Datenanalyse. Im Zuge dessen habe ich über die reine Datenbereinigung hinaus einen vollständigen

Masterplan sowie die gemeinsame Code-Infrastruktur für das gesamte Projekt erstellt.

Arbeitsschritte

0. Gruppentreffen 3 (*ca. 2,5 h*)

- Teilnahme am Gruppentreffen 3 (09:00–11:30 Uhr): Präsentation des bisherigen Stands, Diskussion der Aufgabenverteilung P1–P5, Abstimmung über Projektstruktur und Zeitplan. (*ca. 2,5 h*)

1. Masterplan und Aufgabenverteilung (*ca. 3 h*)

- **Masterplan.md** geschrieben: Projektphasen (Setup → EDA/Baseline → Individuelle Methoden → Vertiefung → Portfolio), Zuordnung der Methoden zu fünf Personen (P1–P5), Bewertungshinweise, Projektstruktur. (*ca. 90 min*)
- **Aufgabenübersicht.md** erstellt: Für jede der fünf Aufgaben eine kurze Beschreibung (Was macht man? Schwierigkeiten? Schwierigkeitsgrad?), damit sich die Teammitglieder orientiert eine Aufgabe auswählen können. (*ca. 60 min*)
- Die Idee hinter der Aufteilung: Jede Person bearbeitet einen eigenen methodischen Schwerpunkt (Regularisierung, Decision Trees, Ensemble, kNN, Neuronales Netz), sodass sich die individuellen Logbücher inhaltlich unterscheiden — wichtig für die 40 %-Bewertung der Logbuch-Zusammenfassung laut Aufgabenstellung. Konzept schriftlich ausgearbeitet und im Masterplan dokumentiert. (*ca. 30 min*)

2. Python-Umgebung & TensorFlow (*ca. 3 h*)

- **Python-Versionsproblem entdeckt:** Am Gruppentreffen 1 hatten wir Python 3.14.3 vereinbart. Beim Versuch, TensorFlow zu installieren, scheiterte `pip install tensorflow` — es existieren keine Wheels für Python 3.14. TensorFlow unterstützt offiziell bis Python 3.13 (ab TF 2.18). Fehleranalyse und Recherche der offiziellen TF-Kompatibilitätsmatrix. (*ca. 60 min*)

- **Lösung:** Auf meinem System (Arch Linux) war `python3.13` bereits installiert. Virtuelle Umgebung neu erstellt:

```
python3.13 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
```

(*ca. 30 min*)

- TensorFlow 2.20.0 erfolgreich installiert und mit einem kurzen Testskript verifiziert (`tf.__version__`, einfaches Dense-Modell). (*ca. 30 min*)

- **requirements.txt** erstellt mit allen benötigten Paketen: `numpy`, `pandas`, `matplotlib`, `seaborn`, `scikit-learn`, `tensorflow`, `jupyter`, `ipykernel`, `nbstripout`. Versionen recherchiert und auf Kompatibilität geprüft. (ca. 60 min)

3. Gemeinsames Utils-Modul (`utils/`) (ca. 12 h) Damit alle Teammitglieder auf identischen Daten und einheitlichen Metriken arbeiten, habe ich ein zentrales Python-Modul erstellt:

- **`utils/data.py`** — Laden des California-Housing-Datensatzes, Datenbereinigung (Cut-offs bei `MedHouseVal` = 5.001 und `HouseAge` = 52, Ausreißer über 98. Perzentil bei `AveRooms`, `AveBedrms`, `Population`, `AveOccup`), standardisierter Train/Test-Split (80/20, `random_state=42`), optionale Skalierung (MinMax / Standard). (ca. 4 h)
 - Die Bereinigungs-schritte orientieren sich an den Vorlesungsunterlagen (Blatt 9/10 Lösung). Lösung nachvollzogen, Cut-off-Werte reproduziert und im Code kommentiert. (in obigen 4 h enthalten)
- **`utils/evaluation.py`** — Einheitliche Auswertung: R^2 , MAE, RMSE für Train- und Testdaten. Globale Ergebnis-Sammlung (`add_result()`, `compare_models()`), damit am Ende eine gemeinsame Vergleichstabelle über alle Modelle entsteht. (ca. 2 h)
- **`utils/plotting.py`** — Standardisierte Visualisierungen: Predicted-vs-Actual-Plot, Residuenplot, Feature-Importances, Korrelations-Heatmap, Histogramme, Features-vs-Target-Scatterplots. Alle Plots werden automatisch als PNG und PDF nach `results/` exportiert (wie in der Aufgabenstellung gefordert: keine Screenshots). Design und Formatierung iterativ angepasst. (ca. 5 h)
- **`utils/__init__.py`** — Re-Export der wichtigsten Funktionen für einfachen Import in den Notebooks. Testen aller Importe in einem Scratch-Notebook. (ca. 60 min)

4. Notebooks erstellt (ca. 8 h) Acht Notebooks angelegt, die den Phasen des Masterplans entsprechen. Für jedes Notebook: Grundstruktur aufgebaut, Imports eingerichtet, `sys.path`-Eintrag gesetzt, Datenladen-Zelle vorbereitet, Platzhalter-Abschnitte für Methodik und Auswertung angelegt, abschließende Ergebniszelle mit `add_result()`-Aufruf vorbereitet. (ca. 1 h pro Notebook)

Notebook	Inhalt
<code>0a_EDA.ipynb</code>	Explorative Datenanalyse: Histogramme, Scatterplots, Korrelationsheatmap (roh und bereinigt)
<code>0b_Baseline_Lineare_Regression.ipynb</code>	Lineare Regression als Referenzmodell (alle Features, nur <code>MedInc</code>), Pred-vs-Actual, Residuen

Notebook	Inhalt
0c_Scaling_Data.ipynb	Vergleich verschiedener Skalierungsmethoden (MinMax, Standard) mit Visualisierung
01_LASSO_Ridge.ipynb	P1: LassoCV/RidgeCV mit/ohne Skalierung, polynomiale Features
02_Decision_Tree.ipynb	P2: Entscheidungsbaum, Depth-Tuning, Pruning, Feature Importances
03_Ensemble.ipynb	P3: Random Forest, Gradient Boosting, GridSearchCV
04_kNN_Regression.ipynb	P4: kNN-Regression, Skalierungseffekt, k-Optimierung
05_Neural_Network.ipynb	P5: TensorFlow/Keras NN, verschiedene Architekturen, Vergleich mit LR

- Jedes Notebook importiert die gemeinsamen Funktionen aus `utils/` und arbeitet auf demselben bereinigten Datensatz mit identischem Split. (*in obigen 8 h enthalten*)
- Die Notebooks sind inhaltlich so vorbereitet, dass jedes Teammitglied direkt mit seinem Schwerpunkt starten kann — die Grundstruktur (Daten laden, Ergebnis speichern, Plots exportieren) ist in jedem Notebook bereits angelegt. (*in obigen 8 h enthalten*)

5. EDA & Baseline durchgeführt (ca. 5 h)

- **EDA (0a_EDA.ipynb):** Rohdaten untersucht (20.640 Samples, 8 Features, keine fehlenden Werte), Histogramme vor und nach Bereinigung erstellt, Korrelationsheatmap zeigt stärkste Korrelation zwischen `MedInc` und `MedHouseVal`. Nach Bereinigung verbleiben ca. 17.386 Samples. Plots exportiert und Interpretation schriftlich festgehalten. (*ca. 3 h*)
- **Baseline (0b_Baseline_Lineare_Regression.ipynb):** Lineare Regression auf allen 8 Features: R^2 Test **0.633**, MAE 0.434, RMSE 0.578. Residuenplot zeigt systematische Muster → nicht-lineare Zusammenhänge, die lineare Regression nicht erfassen kann. Interpretation und Kommentare im Notebook ergänzt. (*ca. 2 h*)

6. nbstripout & .gitignore-Konfiguration (ca. 2 h)

- Mehrere Versuche, `nbstripout` und `.gitignore` korrekt zu konfigurieren. `nbstripout` funktionierte zunächst nicht zuverlässig als Git-Hook (Outputs wurden trotzdem committet). Problem lag an fehlender `.gitattributes`-Konfiguration. Debugging und erneute Einrichtung. (*ca. 90 min*)

- `.gitignore` für `results/*.pdf` eingerichtet, dann wieder angepasst, da einige PDFs doch versioniert werden sollten. Mehrere Commits nötig. (*ca. 30 min*)

Entscheidungen

Entscheidung	Begründung
Python 3.13 statt 3.14	TensorFlow-Inkompatibilität mit Python 3.14
TensorFlow 2.20.0	Neueste Version, kompatibel mit Python 3.13
RANDOM_STATE = 42 (global)	Reproduzierbare Ergebnisse, identischer Split für alle Teammitglieder
Test-Split 20 %	Standard-Aufteilung, wie in Vorlesung verwendet
Ausreißer-Grenze: 98. Perzentil	Orientierung an der Vorlesung (Blatt 9/10 Lösung)
Getrennte Notebooks pro Methode	Weniger Merge-Konflikte in Git, klare Zuordnung zu Personen
Gemeinsames <code>utils/-</code> Modul	Einheitliche Daten, Metriken und Plots für alle Teammitglieder

Schwierigkeiten

- **TensorFlow + Python 3.14:** Keine kompatiblen Wheels verfügbar. Lösung: Wechsel auf Python 3.13.
- **utils als lokales Modul:** `requirements.txt` enthielt zunächst `utils>=0.1.0` (ein fremdes PyPI-Paket). Entfernt — das lokale `utils/-`Modul wird über den Notebook-internen `sys.path`-Eintrag eingebunden.
- **nbstripout-Konfiguration:** Mehrere Anläufe nötig, bis der Git-Hook zuverlässig funktionierte.
- **.gitignore für PDFs:** Zunächst alle PDFs ignoriert, dann einzelne wieder freigegeben — erforderte mehrere Commits, um die gewünschte Konfiguration zu erreichen.

Offene Fragen

- Aufgabenverteilung P1–P5 steht noch nicht fest; soll im nächsten Gruppentreffen besprochen werden.

Eintrag 4 – Python-Versionskonflikt auf macOS (Intel)

Datum: 20.02.2026

Zeitraum: Während und nach Gruppentreffen 3 (9:00–11:30 Uhr)

Gesamtzeit: ca. 2 h

Arbeitsschritte

- Während des Gruppentreffens 3 am 20.02. hat Kolja versucht, die Umgebung auf seinem Intel-Mac einzurichten. Problem live beobachtet und gemeinsam analysiert. (*ca. 30 min*)
- **Problem:** TensorFlow ab Version 2.17 unterstützt keine Intel-Macs mehr (nur Apple Silicon oder Linux/Windows). Python 3.13 + TensorFlow 2.20 (mein Setup auf Arch Linux) lässt sich auf Koljas Mac nicht installieren. Recherche der offiziellen TF-Release-Notes und PyPI-Paketmetadaten. (*ca. 45 min*)
- Kolja hat als Workaround die `requirements.txt` auf Python 3.11 und TensorFlow 2.16.2 angepasst — diese Version unterstützt noch Intel-Macs. Änderung geprüft und im Repository nachvollzogen. (*ca. 20 min*)
- **Offene Entscheidung:** Es steht noch aus, ob wir einheitlich auf Python 3.11 + TF 2.16 wechseln oder ob unterschiedliche lokale Umgebungen akzeptiert werden. Optionen schriftlich festgehalten und Vor-/Nachteile abgewogen. (*ca. 25 min*)

Schwierigkeiten

- Inkompatibilität von TensorFlow 2.17 mit macOS auf Intel-Prozessoren.
- Falls auf TF 2.16 gewechselt wird, muss geprüft werden, ob alle Notebook-Features kompatibel bleiben.

Nächster Schritt

- Klärung der Python-/TensorFlow-Version im nächsten Gruppentreffen.
- Mögliche Alternativen: JLU JupyterHub für rechenintensive Aufgaben (wurde bereits am Gruppentreffen 2 am 17.02. als Option angesprochen).

Eintrag 5 – Auswertung und derzeitiges Fazit: Neuronales Netz (05_Neural_Network.ipynb)

Datum: 23.02.–26.02.2026

Zeitraum: Selbststudium, verteilt auf mehrere Abende

Gesamtzeit: ca. 11 h

Arbeitsschritte

- Kursunterlagen zu Neuronale Netzen (Kapitel 3.3, Blatt 11/12) sowie TensorFlow/Keras-Dokumentation zur Auffrischung durchgelesen. (*ca. 90 min*)
- Notebook-Struktur aufgebaut: Abschnitte für Datenloading, Modellarchitektur, Training, Auswertung und Fazit angelegt; Imports und `sys.path`-Eintrag eingerichtet. (*ca. 45 min*)
- Grundmodell (einzelnes Dense-Layer) implementiert, kompiliert und trainiert; erste Metriken abgelesen und mit der Baseline verglichen. (*ca. 60 min*)
- Verschiedene Architekturen (Modell 1–5) systematisch implementiert und getestet: schrittweise tiefere Netze ([64], [128,64], [128,64,32], [128,64,32,16], [128,64,32,16] + Dropout). Pro Modell: Training über 300 Epochen, Loss-Kurven betrachtet, R^2 / MAE / RMSE notiert. (*ca. 4 h*)
- Dropout-Regularisierung eingebaut; Overfitting-Verhalten von Modell 3 vs. Modell 5 analysiert und im Notebook kommentiert. (*ca. 45 min*)
- **Zusammenfassungszelle in 05_Neural_Network.ipynb ausgefüllt:** Die zuvor mit „*eintragen*“ platzhalterten Felder in der Vergleichstabelle (Abschnitt 7.10) wurden mit den tatsächlichen Messwerten aus den Notebook-Outputs befüllt. (*ca. 30 min*)
- **Ergebnisse abgelesen** aus den Zell-Outputs der bereits ausgeführten Modellzellen:

Aspekt	Lineare Regression	Bestes NN ([128,64,32,16] + Dropout)
R^2 Test	0.6326	0.7795
MAE Test	0.4341	0.3066
Trainingszeit	< 1 s	~1–2 min (300 Epochs, CPU)

- **Fazit formuliert:** Das NN übertrifft die lineare Regression um ~18 Prozentpunkte R^2 und ~0.13 MAE (in 100.000 USD). Als Begründung wurde der nichtlineare Charakter des California-Housing-Datensatzes herausgearbeitet. Grenzen (Overfitting ohne Regularisierung, fehlende Interpretierbarkeit, hoher Tuning-Aufwand) sowie mögliche Verbesserungen (Early Stopping, LR-Scheduling, Ensembling) wurden dokumentiert. (*ca. 90 min*)
- Logbuch-Eintrag verfasst, Ergebnisse strukturiert zusammengefasst, Entscheidungen begründet. (*ca. 60 min*)

Entscheidungen

Entscheidung	Begründung
Modell 5 ([128,64,32,16] + Dropout) als bestes Modell	Höchster R^2 Test (0.7795) bei gleichzeitig geringster Generalisierungslücke dank Dropout
Overfitting-Vergleich Modell 3 vs. Modell 5 explizit erwähnt	Zeigt konkret den Nutzen von Dropout-Regularisierung

Schwierigkeiten

- Keine; Metrikwerte lagen bereits als Notebook-Output vor.

Eintrag 6 – Code-Review, Gruppentreffen 5 und Git-Support

Datum: 14.03.–17.03.2026 **Zeitraum:** Verteilt über mehrere Tage, Gruppentreffen am 17.03. (17:00–19:00 Uhr) **Gesamtzeit:** ca. 6 h

Arbeitsschritte

1. Code-Review und Beobachtung der Contributions (ca. 1,5 h)

- Zwischen dem 14. und 17. März kontinuierlich den Git-Commit-Verlauf beobachtet und neue Contributions der Teammitglieder verfolgt. Insgesamt wurden in diesem Zeitraum ca. 30–40 Commits von verschiedenen Teammitgliedern eingereicht. (ca. 30 min)
- **Felix H.:** Mehrere Commits zu seinem Neuronalen-Netz-Notebook (05_Neural_Network_Felix.ipynb): Feature-Selektion implementiert, Random Search mit 100 Modellen durchgeführt, Learning-Rate-Schedule integriert, verschiedene Ensemble-Methoden getestet. Bester Testscore: $R^2 = 0.7946$. Code durchgelesen und Ansätze nachvollzogen. (ca. 45 min)
- **Kolja:** Weiterarbeit an seinem NN-Notebook (05_Neural_Network_Kolja.ipynb), Training stabilisiert, Vergleich mit anderen Modellen ergänzt. Mehrere Logbuch-Einträge committed. (ca. 15 min)
- **Felix N. und Björn:** Initiale Logbücher angelegt (Logbuch_Felix_Neumann.md, Logbuch_Björn_Becker.md vermutlich). Beide haben begonnen, ihre Arbeit zu dokumentieren. (ca. 20 min)

2. Gruppentreffen 5 am 17.03. (17:00–19:00 Uhr) (ca. 2 h)

- Teilnahme am Gruppentreffen 5 via Discord. Alle fünf Teammitglieder anwesend (Florian, Kolja, Felix N., Felix H., Björn). (ca. 2 h)

- **Vorstellung der Zwischenergebnisse:** Kolja und Felix H. haben ihre bisherigen Ergebnisse zu den Neuronalen Netzen präsentiert. Felix H. hat seine Erkenntnisse zur Feature-Selektion vorgestellt: Manche Features tragen mehr Rauschen als Informationsgewinn bei; durch Reduktion auf wenige relevante Features konnte er bessere Ergebnisse erzielen. Außerdem wurde festgestellt, dass die Variation bei erneutem Trainieren sehr groß ist, was eine systematische Hyperparameter-Optimierung erschwert. *(in obigen 2 h enthalten)*
- **Aufgabenverteilung für die Endphase besprochen:** Person 1 soll Hyperparameter-Optimierung durchführen (Lernrate, Batch Size, Architektur, Regularisierung), Person 2 soll Modellvergleich mit alternativen Modellen (Random Forest, Gradient Boosting) durchführen. Björn und Felix N. wurden beauftragt, die bisherigen Ergebnisse zu konsolidieren und verständlich zu dokumentieren. *(in obigen 2 h enthalten)*
- **Organisatorisches:** Einigung auf Zitierstil (Harvard), LaTeX-Vorlage für Gruppenergebnisse soll erstellt werden, mindestens ein weiteres Treffen in KW 13 geplant (Datum noch offen). *(in obigen 2 h enthalten)*
- **GitHub-Probleme thematisiert:** Mehrere Teammitglieder berichteten von Schwierigkeiten mit Git-Befehlen (Push, Pull, Merge-Konflikte). Vereinbart, dass ich nach dem Treffen Unterstützung leiste. *(in obigen 2 h enthalten)*

3. Git/GitHub-Support für Björn und Felix N. *(ca. 2,5 h)*

- **Björn:** Beim Gruppentreffen hat Björn Probleme beim Pushen seines Logbuchs gemeldet. Gemeinsam via Screensharing (Discord) das Problem analysiert: Lokale Änderungen waren nicht committed, außerdem lagen Remote-Änderungen vor, die noch nicht gepullt wurden. *(ca. 45 min)*
 - Schritt für Schritt durch den Workflow geführt: `git status` → `git add portfolio/Logbuch_Björn_Becker.md` → `git commit -m "Logbuch erstellt"` → `git pull --rebase` → `git push`. Push erfolgreich durchgeführt. *(in obigen 45 min enthalten)*
 - Zusätzlich erklärt, wie man Merge-Konflikte in VS Code löst (Konfliktmarker <<<<<<, =====, >>>>>> identifizieren, gewünschte Version auswählen oder manuell integrieren, dann `git add` und `git rebase --continue`). *(ca. 20 min)*
 - **Notebook-Output-Problem:** Björn hatte beim Comitten von Koljas Notebook (05_Neural_Network_Kolja.ipynb) bemerkt, dass die Datei über 1000 Zeilen Output enthielt, obwohl `nbstripout` eingerichtet war. Problem identifiziert: `nbstripout` war auf Björns System nicht als Git-Hook installiert. Gemeinsam `nbstripout --install` ausgeführt und mit einem Test-Commit verifiziert. Commit 01cb181 ("Problemlösung") reduzierte die Notebook-Datei von 1080 auf 71 Zeilen. *(ca. 30 min)*
- **Felix N.:** Felix N. hatte Schwierigkeiten beim Initialisieren seines Logbuchs und beim Pushen. Problem ähnlich wie bei Björn: Unklare Reihen-

folge von Add, Commit, Pull, Push. (ca. 30 min)

- Git-Workflow nochmals Schritt für Schritt erklärt: Lokale Änderungen → `git add` → `git commit` → `git pull` (um Remote-Änderungen zu holen) → `git push`. (in obigen 30 min enthalten)
- Visual Studio Code als Git-GUI vorgestellt: Source-Control-Tab gezeigt, Staging-Bereich erklärt, Commit-Message-Feld demonstriert. Felix N. hat dann eigenständig sein Logbuch committed und gepusht (Commit `be44740`: “initial logbook Felix_Neumann”). (ca. 25 min)
- **Felix H.:** Felix H. hatte am 14.03. zwei Merge-Konflikte gehabt (Commits `b75b0b4` und `84a2e01`: “Git Konflikt”). Nachträglich den Diff dieser Commits angeschaut: Konflikte in `05_Neural_Network_Felix.ipynb` und `Logbuch_Felix_Hollfoth.md`. Felix H. hatte die Konflikte bereits selbst gelöst, aber ich habe ihm nachträglich erklärt, wie man solche Konflikte vermeiden kann (häufiger pullen, kleinere Commits, Kommunikation im Team). (ca. 20 min)

Entscheidungen

Entscheidung	Begründung
Git-Support via Screensharing (Discord)	Ermöglicht direkte visuelle Anleitung und schnellere Problemlösung
VS Code als Git-GUI empfohlen	Niedrigere Einstiegshürde für Teammitglieder mit wenig Git-Erfahrung

Schwierigkeiten

- **Git-Workflow-Verständnis:** Björn und Felix N. hatten beide anfängliche Schwierigkeiten mit der korrekten Reihenfolge von Git-Befehlen (Add → Commit → Pull → Push). Beide haben jetzt ein grundlegendes Verständnis.
- **nbstripout nicht auf allen Systemen aktiv:** Kolja undd vermutlich Björn hatte `nbstripout` nicht als Git-Hook installiert, obwohl es in der `Ressources.md` dokumentiert war. Problem gelöst, aber zeigt, dass die initiale Setup-Dokumentation möglicherweise noch nicht von allen Teammitgliedern vollständig umgesetzt wurde.
- **Merge-Konflikte bei Felix H.:** Zwei Merge-Konflikte in einer Woche deuten darauf hin, dass die Team-Kommunikation über parallele Änderungen noch verbessert werden kann.

Nächste Schritte

- Weitere Unterstützung bei Git-Problemen anbieten, falls nötig.
- Aufbereitung der Ergebnisse im nächsten Gruppentreffen (KW 13) verfolgen.

- Prüfen, ob alle Teammitglieder `nbstripout` korrekt installiert haben.

Eintrag 7 – Nachtrag Gruppentreffen 4 und Neupriorisierung auf NN

Datum: 27.02.2026

Zeitraum: 15:00–17:15 Uhr (Gruppentreffen 4) + Nachbereitung

Gesamtzeit: ca. 3,5 h

Arbeitsschritte

- Teilnahme am Gruppentreffen 4 (Discord) mit allen Teammitgliedern; gemeinsamer Abgleich, dass wir in den vorherigen Schritten teils zu breit gearbeitet hatten und den Fokus klarer auf Neuronale Netze legen. (*ca. 2,25 h*)
- Ergebnisse zur bisherigen Datenbereinigung/Skalierung und zur Ordner- und Notebook-Struktur vorgestellt; abgestimmt, welche Teile als stabile Basis bestehen bleiben und welche Abschnitte für den NN-Fokus reduziert werden. (*ca. 25 min*)
- Technische Entscheidung zur Umgebung dokumentiert: Trotz TensorFlow-/Python-Problemen auf verschiedenen Systemen bleiben wir bei TensorFlow und akzeptieren zunächst inhomogene lokale Python-Versionen, solange Ergebnisse reproduzierbar dokumentiert werden. (*ca. 20 min*)
- Nach dem Treffen eigene Aufgaben neu priorisiert (weniger neue Baustellen, stärkerer Fokus auf Modellvergleich und Aufbereitung belastbarer NN-Ergebnisse für Portfolio/Logbuch). (*ca. 40 min*)

Entscheidungen

Entscheidung	Begründung
Fokusverschiebung auf Neuronale Netze	Passt besser zur Aufgabenstellung und zum bereits investierten Aufwand im Team
Heterogene Python-Setups zunächst akzeptieren	Praktische Lösung für unterschiedliche Systeme bei gleichzeitigem Zeitdruck

Schwierigkeiten

- Versionsthemen (TensorFlow/Python) blieben ein Risiko, konnten aber durch klare Dokumentation und reproduzierbare Notebook-Schritte abgefedert werden.

Eintrag 8 – Nachtrag Gruppentreffen 6 und Notebook-Outputs ohne nbstripout

Datum: 26.03.2026

Zeitraum: 17:30–19:30 Uhr (Gruppentreffen 6) + technische Umsetzung danach

Gesamtzeit: ca. 5 h

Arbeitsschritte

- Teilnahme am letzten Gruppentreffen (Discord): Vorstellung der Arbeiten von Felix N. und Björn, Abstimmung zur finalen Formatierung und Klärung der letzten Abgabeschritte. (*ca. 2 h*)
- Beschluss aus dem Treffen umgesetzt: Notebooks sollen in der finalen Fassung mit sichtbaren Zell-Outputs vorliegen, damit Ergebnisse für Korrektur und Nachvollziehbarkeit direkt erkennbar sind. (*ca. 20 min Planung*)
- **nbstripout** lokal deaktiviert (**nbstripout --uninstall**) und die relevanten Notebooks erneut vollständig ausgeführt, um Outputs konsistent zu speichern. Anschließend Result-Grafiken aktualisiert und mitgeprüft. (*ca. 2 h*)
- Änderungen in einem eigenen Commit dokumentiert: **2a0cfc2** (*“nbstripout deinstalliert, notebooks durchlaufen lassen. Output ist nun in allen ipynb notebooks abgespeichert!”*). Enthalten waren u. a. `0a_EDA.ipynb`, `0b_Baseline_Lineare_Regression.ipynb`, `05_Neural_Network_Florian.ipynb` sowie aktualisierte Ergebnisgrafiken. (*ca. 40 min inkl. Kontrolle*)

Entscheidungen

Entscheidung	Begründung
Outputs für finale Abgabe sichtbar machen	Bewertende sehen Metriken/Plots direkt im Notebook ohne erneute Ausführung
Eigener, klar benannter Commit für den Schritt	Erhöht Nachvollziehbarkeit im Git-Verlauf

Schwierigkeiten

- Ohne **nbstripout** steigen Dateigröße und Diff-Umfang der Notebooks deutlich; wurde bewusst zugunsten der Sichtbarkeit der Endergebnisse akzeptiert.

Eintrag 9 – Tau-Template bereitgestellt, Titelseite erstellt, Summary vollständig geschrieben

Datum: 28.03.–09.04.2026

Zeitraum: Mehrere Arbeitsblöcke im Selbststudium

Gesamtzeit: ca. 7 h

Arbeitsschritte

- Für die Portfolio-Zusammenfassungen ein geeignetes **Tau-Template** aus Overleaf/GitHub recherchiert, auf Projektkompatibilität geprüft (Struktur, Klassen-Dateien, Bibliographie, Build-Verhalten) und im Repository so abgelegt, dass alle Teammitglieder darauf zugreifen konnten. (ca. 1,5 h)
- Bei der Erstellung/Anpassung der Titelseite für die Summary unterstützt und Layout-/Metadatenfelder (Name, Matrikelnummer, Gruppe, Doctype, Datum) auf die Projektanforderungen abgestimmt. (ca. 1,5 h)
- Eigene vollständige Summary meiner Projektarbeit in `portfolio/Summary_Flo/main.tex` ausformuliert: Fragestellung, Methodik, EDA/Baseline, NN-Vergleich, Grenzen, Ausblick; inkl. Abbildungen/Tabellen und Verweisen auf den Arbeitsprozess. (ca. 3 h)
- Abschlusskorrekturen und Strukturverbesserungen durchgeführt (u. a. sprachliche Korrektur, Affiliation/Format, Literatur- und Build-Feinschliff), sodass die Summary konsistent kompilierbar und inhaltlich vollständig ist. (ca. 1 h)

Entscheidungen

Entscheidung	Begründung
Tau-Template als gemeinsame Grundlage	Einheitliche, professionelle Formatierung über alle Summaries hinweg
Eigene Summary komplett in LaTeX finalisiert	Saubere Referenzierung von Abbildungen/Tabellen und gute Nachvollziehbarkeit

Schwierigkeiten

- Kombination aus inhaltlicher Verdichtung (max. 4 Seiten) und formaler Qualität war aufwändig; erforderte mehrere Iterationen bei Textkürzung und Fokussierung.

Zeitübersicht (Gesamtprojekt)

Eintrag	Datum	Tätigkeit	Zeit
1	11.02.2026	Recherche Git-Workflow & nbstripout	ca. 4 h
2	17.02.2026	Repository- Strukturierung	ca. 3 h
3	20.–25.02.2026	Projektstruktur, Utils, Notebooks, EDA, Baseline	ca. 35 h
4	20.02.2026	Python- Versionskonflikt macOS	ca. 2 h
5	23.–26.02.2026	Neuronales Netz & Auswertung	ca. 11 h
6	14.–17.03.2026	Code-Review, Gruppentreffen 5, Git-Support	ca. 6 h
7	27.02.2026	Nachtrag Gruppentreffen 4 und Neupriorisierung	ca. 3,5 h
8	26.03.2026	Nachtrag Gruppentreffen 6 + Notebooks ohne nbstripout	ca. 5 h
9	28.03.–09.04.2026	Tau-Template, Titelseite, vollständige Summary	ca. 7 h
Gesamt			ca. 76,5 h